Школска година 2026/2027

Предмет: Напредне базе података/Базе података

Пројекат бр. 1б – RAG систем и примена векторских индекса

У овом пројекту је потребно реализовати RAG (Retrieval-Augmented Generation) систем за ефикасно претраживање базе знања на основу информација са веб сајтова (нпр. опис предмета на РАФ-у или другим факултетима, документација неког сложенијег софтверског производа), садржаја неке књиге (рецимо PDF књига као што је то урађено на вежбама), више текстуалних докумената (рецимо каталози неке компаније са описима њихових производа, архива компанијске документације, мејлова, дискусионих група, вести) или садржај неког датасета из друштвених мрежа (нпр. Reddit датасет са архивом постова и коментара). Очекивано је да се у векторски индекс смести **барем 1000 фрагмената** из одабране базе знања.

Циљ пројекта је да се реализују два различита приступа у RAG системима и упореди њихова ефикасност у погледу прецизности проналажења релевантних делова текста на основу векторских индекса, а као додатни параметар за анализу се може узети кашњење одговора одн. брзина одговора система на упите корисника.

Потребно је пажљиво одабрати три корисничка питања која се односе на специфично знање или информацију из креиране базе знања, са јасно издвојеним делом где се специфични текст налази у коришћеном извору и показати који приступ је прецизније издвојио (адекватно рангирао) дати садржај и на основу њега генерисао адекватан одговор кориснику преко LLM-а (препорука је да се користи Groq платформа и неки од отворених језичких модела попут qwen3.8-27b или gpt-oss-120b).

Могући приступи RAG система укључују различите приступе за ембединг (веће или мање димензије, бинарни ембединг), коришћење различитих векторских индекса (HNSW, IVF, IndexFlatL2...), различите технике фрагментације текста (фрагменти текста фиксне дужине, подела текста у реченице, у семантичке целине као што су пасуси итд.), различите приступе за складиштење, индексирање и дохватање фрагмената (целобројна квантизација, поновно рангирање, хијерархијско дохватање фрагмената итд). Као основни приступ (baseline) за поређење, може се користити и стандардна техника за претрагу текста преко инвертованог индекса коришћењем Lucene библиотеке.

Пројекат имплементирати у Python-у, а приступ са инвертованим индексом и Lucene-ом имплементирати у Јави (ако се користи наравно).

Комплетна реализација пројекта **носи 10 поена** са јасно назначеним питањима и одговорима из поређених приступа, са додатно наведеним временима извршавања ако се и то узима у обзир.

Додатни наградни поени се могу добити применом посебних инвентивних приступа који побољшавају прецизност и/или брзину одговора. Ако се буде користила нека база знања на српском језику, то ће донети **додатна 2 поена** (ту је нагласак на одабир ембединг модела који ефикасно покрива српски језик) **. Максимални број наградних поена је 5.**

Напомене:

- Одбрана пројекта подразумева апсолутно познавање сваког дела креираног програмског кода и захтеваће се имплементација неке мање промене у постојећи код на лицу места са временским роком за имплементацију.
- Преписани пројекти неће бити признати, а веома слични пројекти ће посебно бити анализирани и захтеваће се додатне провере.
- **Ако нешто није довољно јасно дефинисано, оставља се студентима да уведу разумну претпоставку.**
- Пројекат се шаље имејлом, на адресу zbabovic@raf.rs и bstikovic@raf.rs, са насловом: НБП/БП 2026 – Пројекат бр. 1б.
- Рок за предају пројекта је субота 21.11. до 10:00h.
- Одбрана пројекта ће бити одржана у недељу 22.11.